PROPOSAL PENELITIAN

Disusun untuk memenuhi tugas Ujian Tengah Semester (UTS) Mata Kuliah Riset Informatika

IMPLEMENTASI METODE 2D-CONVOLUTIONAL NEURAL NETWORK UNTUK KLASIFIKASI JENIS EMOSI BERBASIS UCAPAN

AILSA FARAH HAMIDAH
NPM 23081010212

DOSEN PENGAMPU

Basuki, S.Kom., M.Kom.

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2026

DAFTAR ISI

DAFTAR ISI.....ii

DAFTAR GAMBAR.....iv

DAFTAR TABEL.....v

BAB I PENDAHULUAN.....1

1.1. Latar Belakang.....1

1.2. Rumusan Masalah.....3

1.3. Tujuan Penelitian.....3

1.4. Manfaat Penelitian.....4

1.5. Batasan Masalah.....4

1.6. Sistematika Penulisan.....5

BAB II TINJAUAN PUSTAKA.....6

2.1. Penelitian Terdahulu.....6

2.2. Research Gap.....8

2.3. Landasan Teori.....9

2.3.1. Emosi dan Speech Emotion Recognition.....9

2.3.2. Sinyal Ucapan dan Short-Time Fourier Transform.....10

2.3.3. Mel Spectrogram dan Log-Mel Spectrogram……10

2.3.4. Mel-Frequency Cepstral Coefficients……...…11

2.3.5. Augmentasi Data Audio.....11

2.3.6. Convolutional Neural Network.....11

2.3.7. 2D-CNN pada Representasi Waktu-Frekuensi.....13

2.3.8. Overfitting dan Evaluasi Speaker-Independent.....13

2.4. Research Mind Map.....13

2.5. Hipotesis Penelitian.....14

BAB III METODOLOGI PENELITIAN.....16

3.1. Jenis dan Pendekatan Penelitian.....16

3.2. Tahapan Penelitian.....16

3.3. Dataset Rencana Riset Kecil.....18

3.3.1. Sumber dan Spesifikasi Dataset.....18

3.3.2. Struktur Penamaan Berkas dan Pelabelan.....19

3.3.3. Distribusi Kelas Emosi.....19

3.3.4. Pembagian Data Speaker-Independent.....20

3.4. Pra-pemrosesan Audio.....20

3.5. Ekstraksi Fitur.....21

3.6. Augmentasi Data.....22

3.7. Rancangan Arsitektur 2D-CNN.....22

3.8. Skenario Eksperimen dan Konfigurasi Pelatihan……....23

3.9. Rencana Evaluation Metric.....24

3.9.1. Accuracy.....25

3.9.2. Precision, Recall, dan F1-Score.....25

3.9.3. Macro F1-Score dan Unweighted Average Recall.....25

3.9.4. Confusion Matrix dan Analisis Overfitting.....25

3.9.5 Uji Signifikansi McNema.....26

3.10 Implementasi Website.....26

DAFTAR PUSTAKA.....27

DAFTAR GAMBAR

Gambar 2.1. Research Mind Map Penelitian Klasifikasi Jenis Emosi Berbasis Ucapan Menggunakan 2D-CNN 14
Gambar 3.1. Diagram Alur Tahapan Penelitian 17
Gambar 3.2. Alur Ekstraksi Fitur Log-Mel Spectrogram dan MFCC-2D ... 21
Gambar 3.3. Rancangan Arsitektur 2D-CNN Ringan 23
Gambar 3.4. Wireframe Website 26

DAFTAR TABEL

Tabel 2.1. Matriks Perbandingan Penelitian Terdahulu 8
Tabel 2.2. Identifikasi Research Gap dan Respons Penelitian 8
Tabel 3.1. Spesifikasi Dataset RAVDESS yang Digunakan 18
Tabel 3.2. Struktur Kode Nama Berkas RAVDESS 19
Tabel 3.3. Distribusi Kelas Emosi pada RAVDESS Speech 19
Tabel 3.4. Rencana Pembagian Data Berdasarkan Aktor 20
Tabel 3.5. Parameter Ekstraksi Fitur 21
Tabel 3.6. Rencana Teknik Augmentasi Data 22
Tabel 3.7. Rincian Lapisan Arsitektur 2D-CNN (Masukan Log-Mel 64×301×1) 23
Tabel 3.8. Skenario Eksperimen 24
Tabel 3.9. Konfigurasi Pelatihan 2D-CNN 24
Tabel 3.10. Ringkasan Rencana Evaluation Metric 26
Tabel 3.11. Komponen Implementasi Website 28
Tabel 3.12. Rencana Skenario Black-Box Testing Website 29
Tabel 3.13. Lingkungan dan Alat Penelitian 29
Tabel 3.14. Jadwal Rencana Penelitian 30

BAB I
PENDAHULUAN

1.1. Latar Belakang

Ucapan merupakan media komunikasi yang paling alami dan paling sering digunakan manusia. Selain membawa informasi leksikal berupa kata dan kalimat, sinyal ucapan juga membawa informasi paralinguistik seperti usia, jenis kelamin, bahasa, dan kondisi emosional penutur [1]. Emosi tercermin melalui variasi nada (*pitch*), intensitas, tempo bicara, dan kualitas suara, sehingga kalimat yang sama dapat dimaknai berbeda apabila diucapkan dengan emosi yang berbeda. Kemampuan mesin untuk mengenali emosi dari ucapan merupakan bagian dari *affective computing*, yaitu bidang yang mempelajari bagaimana sistem komputasi dapat mengenali, memproses, dan merespons emosi manusia [2].

Pengenalan emosi berbasis ucapan atau *Speech Emotion Recognition* (SER) memiliki peluang penerapan yang luas, antara lain pada layanan pelanggan (*call center*) untuk memantau kepuasan pelanggan, interaksi manusia dan komputer (*human-computer interaction*), sistem pembelajaran digital, hingga pemantauan kesehatan mental [3], [4], [5]. Dibandingkan pengenalan emosi berbasis ekspresi wajah yang sensitif terhadap pencahayaan dan sudut kamera, pendekatan berbasis suara tidak memerlukan perangkat khusus dan dapat menangkap respons pengguna secara alami [6].

Secara umum, penelitian SER menghadapi dua persoalan utama, yaitu pemilihan fitur akustik dan pemilihan model klasifikasi [7]. Pendekatan awal mengandalkan fitur yang dirancang manual (*handcrafted features*) seperti *Mel-Frequency Cepstral Coefficients* (MFCC), *pitch*, energi, dan fitur spektral yang kemudian diklasifikasikan menggunakan algoritma konvensional seperti *Support Vector Machine* (SVM) atau *Hidden Markov Model* (HMM) [1], [8]. Perkembangan *deep learning*, khususnya *Convolutional Neural Network* (CNN), memungkinkan model mempelajari fitur secara otomatis dari representasi data mentah maupun semi-mentah [9], [10]. Representasi waktu-frekuensi seperti *spectrogram* dapat diperlakukan layaknya citra: sumbu horizontal menyatakan waktu dan sumbu vertikal menyatakan frekuensi. Dengan demikian, *2D-Convolutional Neural Network* (2D-CNN) dapat mempelajari pola lokal pada bidang waktu-frekuensi, misalnya

pergeseran formant dan perubahan distribusi energi, yang menjadi ciri khas masing-masing emosi [11], [6].

Sejumlah penelitian terdahulu menunjukkan potensi pendekatan tersebut. Reggiswarashari dan Sihwi [7] menerapkan 2D-CNN pada 13 koefisien MFCC dengan segmentasi audio dan gabungan dataset RAVDESS, SAVEE, dan TESS untuk tujuh kelas emosi, dengan akurasi 83,69%; namun penulis menyatakan bahwa angka tersebut mencakup data yang juga digunakan saat pelatihan, sedangkan pengujian pada 500 sampel menghasilkan akurasi 73,60% dan pelatihan pada RAVDESS saja hanya mencapai 40,19%. Kim dan Lee [6] melaporkan bahwa komponen 2D-CNN pada Mel-Spectrogram secara mandiri mencapai *unweighted accuracy* 70,15% pada RAVDESS, dan meningkat menjadi 80,19% setelah digabung dengan BiLSTM–Transformer yang jauh lebih kompleks. Pada konteks Indonesia, Tanudjaja dkk. [3] memperoleh akurasi 70% untuk delapan kelas emosi RAVDESS dengan fitur MFCC, tetapi kelas netral hanya mencapai *F1-score* 33%, sedangkan Santoso dkk. [4] mencapai akurasi uji 83,35% untuk empat kelas emosi pada dialog film berbahasa Indonesia. Sementara itu, Maulana dkk. [5] menggunakan arsitektur CNN-BiLSTM berparameter sekitar 4,85 juta dengan gabungan Mel-Spectrogram dan MFCC, dan memperoleh akurasi 70,00% disertai selisih akurasi data latih dan validasi sebesar 28,06 poin persentase yang menandakan *overfitting*.

Dari kajian tersebut terdapat beberapa permasalahan yang belum terjawab secara memadai. *Pertama*, sebagian besar penelitian membagi data secara acak pada tingkat berkas atau segmen, sehingga penutur yang sama, bahkan potongan dari rekaman yang sama, dapat muncul pada data latih dan data uji. Skema ini menghasilkan estimasi kinerja yang bersifat *speaker-dependent* dan cenderung optimistis [8]. Hal ini penting pada RAVDESS karena setiap aktor mengucapkan dua kalimat yang sama untuk seluruh emosi [12], sehingga model berisiko mempelajari identitas penutur alih-alih pola emosi. *Kedua*, ukuran dataset emosi yang relatif kecil dipadukan dengan model yang kompleks memicu *overfitting* [7], [5]. *Ketiga*, pilihan representasi masukan masih beragam: ada yang menggunakan vektor fitur statistik pada CNN satu dimensi [3] dan ada yang hanya menggunakan 13 koefisien MFCC [7], sementara perbandingan terkontrol antara Log-Mel Spectrogram dan MFCC dua dimensi pada arsitektur 2D-CNN dan protokol evaluasi yang sama masih terbatas. *Keempat*, pelaporan kinerja masih didominasi metrik akurasi, padahal kelas yang

saling tertukar seperti netral dan tenang memerlukan metrik makro seperti *macro F1-score* dan *Unweighted Average Recall* (UAR) agar setiap kelas dinilai setara [13].

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan implementasi 2D-CNN ringan (sekitar 250 ribu parameter) untuk mengklasifikasikan delapan jenis emosi berbasis ucapan pada dataset RAVDESS. Penelitian membandingkan dua representasi masukan, yaitu Log-Mel Spectrogram dan MFCC dua dimensi (MFCC-2D), menguji pengaruh augmentasi data yang hanya diterapkan pada data latih, serta mengevaluasi model dengan protokol *speaker-independent* melalui pembagian data berdasarkan aktor. Kinerja diukur menggunakan *accuracy*, *macro precision*, *macro recall* (UAR), *macro F1-score*, dan *confusion matrix*. Rancangan ini disusun dalam skala riset kecil: menggunakan satu dataset publik berukuran sekitar 200 MB dan dapat dilatih pada GPU gratis Google Colab. Model terbaik kemudian diimplementasikan ke dalam prototipe *website* berbasis Flask agar dapat digunakan untuk mengklasifikasikan rekaman suara yang diunggah pengguna. Hasil penelitian diharapkan memberikan estimasi kinerja 2D-CNN yang lebih realistis terhadap penutur yang belum pernah dilihat model, sekaligus menjadi dasar pengembangan lanjutan, termasuk penerapan pada data ucapan berbahasa Indonesia sebagaimana disarankan oleh penelitian terdahulu [3], [4].

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana mengimplementasikan arsitektur 2D-CNN ringan untuk mengklasifikasikan delapan jenis emosi berbasis ucapan pada dataset RAVDESS?
2. Bagaimana perbandingan kinerja representasi masukan Log-Mel Spectrogram dan MFCC-2D pada arsitektur 2D-CNN dan konfigurasi pelatihan yang sama?
3. Bagaimana pengaruh augmentasi data terhadap kinerja klasifikasi dan tingkat *overfitting* model?
4. Bagaimana kinerja model terbaik pada skema pengujian *speaker-independent* apabila diukur menggunakan *accuracy*, *macro precision*, *macro recall* (UAR), *macro F1-score*, dan *confusion matrix*?
5. Bagaimana mengimplementasikan model terbaik ke dalam prototipe *website* yang dapat mengklasifikasikan jenis emosi dari rekaman suara yang diunggah pengguna?

1.3. Tujuan Penelitian

Sejalan dengan rumusan masalah, tujuan penelitian ini adalah sebagai berikut.

1. Mengimplementasikan arsitektur 2D-CNN ringan untuk klasifikasi delapan jenis emosi berbasis ucapan pada dataset RAVDESS.
2. Membandingkan kinerja representasi Log-Mel Spectrogram dan MFCC-2D sebagai masukan 2D-CNN dalam kondisi eksperimen yang terkontrol.
3. Menganalisis pengaruh augmentasi data terhadap kinerja klasifikasi dan selisih akurasi data latih dan validasi.
4. Mengevaluasi kinerja model terbaik pada data uji dari aktor yang tidak dilibatkan dalam pelatihan serta mengidentifikasi pasangan kelas emosi yang paling sering tertukar.
5. Mengimplementasikan model terbaik ke dalam prototipe *website* berbasis Flask untuk klasifikasi jenis emosi dari rekaman suara yang diunggah pengguna.

1.4. Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut.

1. **Manfaat akademis**, yaitu memberikan bukti empiris mengenai perbandingan representasi Log-Mel Spectrogram dan MFCC-2D pada 2D-CNN dengan protokol evaluasi *speaker-independent*, serta menjadi rujukan metodologis bagi mahasiswa yang meneliti SER dengan sumber daya terbatas.
2. **Manfaat praktis**, yaitu menghasilkan *pipeline*, model ringan, dan prototipe *website* yang dapat direplikasi serta dikembangkan lebih lanjut menjadi komponen aplikasi, misalnya pemantauan emosi pelanggan pada layanan *call center* atau sistem interaksi manusia dan komputer.
3. **Manfaat bagi pengembangan riset lanjutan**, yaitu menyediakan kerangka eksperimen yang dapat diterapkan ulang pada dataset ucapan berbahasa Indonesia ketika data tersebut tersedia.

1.5. Batasan Masalah

Agar penelitian tetap terarah dan realistis untuk dilaksanakan, ditetapkan batasan masalah sebagai berikut.

1. Dataset yang digunakan adalah RAVDESS bagian *speech audio-only* sebanyak 1.440 berkas berbahasa Inggris beraksen Amerika Utara. Ucapan bersifat diperankan (*acted*), bukan ucapan spontan.

2. Kelas emosi yang diklasifikasikan berjumlah delapan, yaitu netral, tenang, senang, sedih, marah, takut, jijik, dan terkejut.
3. Penelitian hanya menggunakan informasi akustik; informasi leksikal (teks transkrip) dan visual tidak digunakan.
4. Representasi masukan dibatasi pada Log-Mel Spectrogram dan MFCC-2D, sedangkan model utama dibatasi pada 2D-CNN. Arsitektur rekuren, Transformer, dan model pra-latih seperti wav2vec 2.0 tidak termasuk cakupan penelitian.
5. Pelatihan model dilakukan dengan bahasa pemrograman Python pada Google Colab. Model terbaik diimplementasikan sebagai prototipe *website* berbasis Flask yang dijalankan secara lokal dan memproses berkas rekaman yang diunggah; pengenalan emosi secara *real-time* dari mikrofon, aplikasi *mobile*, dan *deployment* ke server publik tidak termasuk cakupan penelitian.
6. Evaluasi dilakukan secara *offline* pada data uji yang berasal dari aktor yang tidak dilibatkan dalam proses pelatihan dan validasi.

1.6. Sistematika Penulisan

Proposal penelitian ini disusun dalam tiga bab dengan sistematika sebagai berikut.

1. **BAB I Pendahuluan**, berisi latar belakang, rumusan masalah, tujuan, manfaat, batasan masalah, dan sistematika penulisan.
2. **BAB II Tinjauan Pustaka**, berisi kajian penelitian terdahulu, identifikasi *research gap*, landasan teori, *research mind map*, dan hipotesis penelitian.
3. **BAB III Metodologi Penelitian**, berisi jenis penelitian, tahapan penelitian, rencana dataset riset kecil, rancangan pra-pemrosesan, ekstraksi fitur, augmentasi, arsitektur 2D-CNN, skenario eksperimen, rencana *evaluation metric*, implementasi *website*, lingkungan penelitian, dan jadwal penelitian.

BAB II
TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Kajian penelitian terdahulu difokuskan pada penelitian SER berbasis CNN yang menjadi acuan utama penelitian ini. Ringkasan masing-masing penelitian diuraikan sebagai berikut.

1. **Speech Emotion Recognition Using 2D-Convolutional Neural Network** oleh Reggiswarashari dan Sihwi [7]. Penelitian ini menggabungkan dataset RAVDESS (1.440 berkas), SAVEE (480 berkas), dan TESS (2.800 berkas) untuk tujuh kelas emosi. Audio disegmentasi secara linear dan *overlap* dengan durasi 2 dan 3 detik, kemudian diekstraksi menjadi 13 koefisien MFCC dan dilengkapi *zero padding* sehingga berbentuk matriks (130, 13) untuk segmen 3 detik. Arsitektur terbaik terdiri atas dua blok konvolusi (64 filter 3×3 dan 64 filter 2×2) dengan *batch normalization* dan *max pooling*, dua *dropout* 0,5, regularisasi L2, *batch size* 44, 30 *epoch*, serta rasio data 8:1:1. Akurasi yang dilaporkan sebesar 83,69%, tetapi pada 500 sampel uji diperoleh *precision* 73,65%, *recall* 73,77%, dan *F1-score* 73,63%. Penggabungan dataset meningkatkan akurasi dibanding dataset tunggal (RAVDESS 40,19%, SAVEE 17,99%, TESS 53,65%, gabungan 69,21%), dan 2D-CNN mengungguli CNN 1D (51,05%) serta RNN-LSTM (58,02%). Kelemahan yang teridentifikasi adalah *overfitting* akibat jumlah data yang kecil dan pembagian data pada tingkat segmen.
2. **A BiLSTM–Transformer and 2D CNN Architecture for Emotion Recognition from Speech** oleh Kim dan Lee [6]. Penelitian ini menggunakan Emo-DB [14] dan RAVDESS dengan enam kelas emosi. Segmen hening dihapus menggunakan fungsi *trim* dari librosa, kemudian Mel-Spectrogram diseragamkan menjadi 2 detik untuk RAVDESS (128×188). Cabang 2D-CNN terdiri atas empat lapisan konvolusi (32, 64, 128, 256 filter 3×3) dengan regularisasi L2 0,001, *global average pooling* dan *global max pooling*, *batch normalization*, serta *dropout* 0,5; cabang lainnya adalah BiLSTM–Transformer yang memproses kumpulan fitur akustik. Dengan *10-fold cross-validation*, model hibrida mencapai *unweighted accuracy* 80,19% pada RAVDESS dan 95,65% pada Emo-DB,

sedangkan 2D-CNN saja mencapai 70,15% dan 85,62%. Model hibrida tersebut menuntut komputasi besar dan fold dibentuk dari sampel yang diacak.

3. **Klasifikasi Jenis Emosi Melalui Ucapan Menggunakan Metode Convolutional Neural Network** oleh Tanudjaja dkk. [3]. Penelitian ini mengklasifikasikan delapan kelas emosi pada 1.440 berkas RAVDESS dengan fitur MFCC, energi, *pitch*, *spectral centroid*, *spectral flatness*, dan *spectral roll-off*. Arsitektur CNN terdiri atas empat lapisan konvolusi (64, 128, 256, dan 256 filter) dengan *dropout* dan *max pooling*, diikuti lapisan *fully connected* 256 neuron dan *softmax*, dilatih selama 50 *epoch* dengan *batch size* 64 dan *optimizer* Adam. Dari empat rasio pembagian data, rasio 80:10:10 memberikan hasil terbaik, dan fitur MFCC saja menghasilkan akurasi tertinggi 70% dengan rata-rata *precision* dan *recall* sekitar 67–68%. Penggabungan seluruh fitur justru menurunkan akurasi menjadi 60%, dan kelas netral memiliki *F1-score* terendah (33%) karena sering tertukar dengan kelas tenang.
4. **Speech Emotion Recognition of Indonesian Movies by Using Convolutional Neural Network** oleh Santoso dkk. [4]. Dataset disusun dari dialog serial berbahasa Indonesia "Imperfect" episode 1–12 dengan delapan aktor berusia 18–58 tahun. Audio dipotong otomatis berdasarkan *subtitle* menjadi 5.049 segmen berdurasi 1–4 detik untuk empat kelas emosi (marah 1.202, senang 1.228, netral 2.075, sedih 899). Fitur yang digunakan adalah 40 koefisien MFCC dengan CNN, *batch normalization*, aktivasi ReLU, dan *dropout* 10% selama 400 *epoch*. Akurasi pelatihan mencapai 85,85% dan akurasi pengujian 83,35%, dengan kelas netral sebagai kelas tersulit karena energinya yang datar. Data latih dan uji berasal dari korpus dan aktor yang sama.
5. **Klasifikasi Emosi Suara Multi Bahasa Berbasis Deep Learning Menggunakan Mel Spectrogram dan MFCC pada Indian Speech Emotion** oleh Maulana dkk. [5]. Penelitian ini menggunakan 1.000 sampel tiga bahasa (Inggris, Hindi, Marathi) untuk lima kelas emosi. Audio di-*resample* ke 22.050 Hz dan diseragamkan menjadi 3 detik. Augmentasi berupa *time stretching*, *pitch shifting* ±2 *semitone*, *Gaussian noise* (SNR sekitar 15 dB), dan *volume scaling* hanya diterapkan pada data latih. Fitur Mel-Spectrogram 128 pita, MFCC 40 koefisien, delta, dan delta-delta digabung menjadi tensor 248×T, lalu diproses CNN-BiLSTM dengan *attention* (sekitar 4,85 juta parameter). Hasilnya adalah

akurasi 70,00% dan *F1-score* rata-rata 0,70, tetapi akurasi latih 96,40% dibanding akurasi validasi 68,33% menunjukkan *overfitting* yang besar akibat kompleksitas model.

Perbandingan kelima penelitian tersebut beserta posisi penelitian yang diusulkan dirangkum pada Tabel 2.1.

Tabel 2.1. Matriks Perbandingan Penelitian Terdahulu

No	Peneliti (Tahun)	Dataset & Kelas	Fitur	Metode	Skema Evaluasi	Hasil Utama
1	Reggiswarashari & Sihwi (2022) [7]	RAVDESS + SAVEE + TESS; 7 emosi	MFCC 13 koefisien, segmentasi + *zero padding*	2D-CNN, 2 blok konvolusi	Split acak 8:1:1 pada tingkat segmen	Akurasi 83,69% (termasuk data latih); F1 73,63% pada 500 sampel
2	Kim & Lee (2023) [6]	Emo-DB, RAVDESS; 6 emosi	Mel-Spectrogram + kumpulan fitur akustik	BiLSTM–Transformer + 2D-CNN	10-fold CV, sampel diacak	UA RAVDESS 80,19%; 2D-CNN saja 70,15%
3	Tanudjaja dkk. (2023) [3]	RAVDESS; 8 emosi	MFCC, energi, *pitch*, fitur spektral	CNN 4 lapisan konvolusi	Split acak 80:10:10	Akurasi 70% (MFCC); F1 netral 33%
4	Santoso dkk. (2025) [4]	Dialog film Indonesia; 4 emosi	MFCC 40 koefisien	CNN	Latih dan uji dari korpus yang sama	Akurasi uji 83,35%; netral tersulit
5	Maulana dkk. (2026) [5]	Indian Speech Emotion; 5 emosi, 3 bahasa	Mel 128 + MFCC 40 + Δ + ΔΔ	CNN-BiLSTM + *attention* (±4,85 juta parameter)	Split 80:20 stratifikasi bahasa-emosi	Akurasi 70,00%; gap latih–validasi 28,06 poin
6	**Penelitian ini**	**RAVDESS; 8 emosi**	**Log-Mel 64×301 vs MFCC-2D 40×301**	**2D-CNN ringan (±250 ribu parameter) + augmentasi**	**Speaker-independent: split per aktor 16/4/4, 3 seed**	**Accuracy, macro P/R/F1, UAR, confusion matrix, McNemar**

2.2. Research Gap

Berdasarkan analisis penelitian terdahulu, celah penelitian (*research gap*) dikelompokkan ke dalam lima aspek. Setiap celah dipetakan ke respons yang dirancang dalam penelitian ini sebagaimana ditunjukkan pada Tabel 2.2.

Tabel 2.2. Identifikasi Research Gap dan Respons Penelitian

No	Aspek	Temuan pada Penelitian Terdahulu	Celah (Gap)	Respons Penelitian Ini
1	Protokol evaluasi	Data dibagi secara acak pada tingkat berkas atau segmen [7], [6], [3]; akurasi tertinggi pada [7] mencakup data yang ikut dilatih.	Kinerja bersifat *speaker-dependent* dan berisiko optimistis karena kebocoran informasi penutur.	Pembagian data per aktor (16/4/4); aktor pada data uji tidak pernah dilihat selama pelatihan.

No	Aspek	Temuan pada Penelitian Terdahulu	Celah (Gap)	Respons Penelitian Ini
2	Kompleksitas model vs ukuran data	*Overfitting* pada data kecil [7]; gap latih–validasi 28,06 poin dengan ±4,85 juta parameter [5]; model hibrida berat [6].	Dibutuhkan model yang proporsional terhadap ukuran data dan sumber daya komputasi mahasiswa.	2D-CNN ringan ±250 ribu parameter dengan *batch normalization*, *dropout*, L2, dan *early stopping*.
3	Representasi masukan	Vektor fitur statistik pada CNN [3]; hanya 13 MFCC [7]; Mel dan MFCC digabung tanpa dibandingkan [5].	Belum ada perbandingan terkontrol Log-Mel dan MFCC-2D pada arsitektur dan protokol yang sama.	Skenario S1 (MFCC-2D) dan S2 (Log-Mel) dengan arsitektur, *hyperparameter*, dan pembagian data identik.
4	Augmentasi data	Augmentasi dipakai bersama model besar [5]; sebagian penelitian tidak menggunakan augmentasi [7], [3].	Pengaruh augmentasi belum diisolasi melalui uji ablasi.	Skenario S3 membandingkan konfigurasi terbaik dengan dan tanpa augmentasi.
5	Metrik pelaporan	Pelaporan didominasi akurasi; kelas netral dan tenang sering tertukar [3], [4].	Kinerja per kelas dan kelas minoritas kurang tergambar.	*Macro F1-score* sebagai metrik utama, UAR, metrik per kelas, *confusion matrix* ternormalisasi, rerata ± simpangan baku 3 *seed*, dan uji McNemar.

Dengan demikian, *research gap* yang diangkat dalam penelitian ini adalah belum tersedianya evaluasi 2D-CNN ringan yang membandingkan representasi Log-Mel Spectrogram dan MFCC-2D secara terkontrol, disertai uji ablasi augmentasi data, pada protokol *speaker-independent* dengan pelaporan metrik makro. Penelitian ini tidak bertujuan mengalahkan angka akurasi tertinggi yang pernah dilaporkan, melainkan menghasilkan estimasi kinerja yang lebih jujur dan dapat direplikasi dengan sumber daya terbatas.

2.3. Landasan Teori

2.3.1. Emosi dan Speech Emotion Recognition

Emosi dapat dimodelkan secara kategorikal maupun dimensional. Model kategorikal mengelompokkan emosi ke dalam kelas diskret seperti marah, senang, sedih, dan takut, sedangkan model dimensional menempatkan emosi pada ruang kontinu, misalnya dimensi *arousal* (tingkat aktivasi) dan *valence* (positif atau negatif) [1], [4]. Penelitian ini menggunakan model kategorikal sesuai label yang tersedia pada dataset RAVDESS [12].

Sistem SER umumnya terdiri atas tahap akuisisi data, pra-pemrosesan, ekstraksi fitur, dan klasifikasi [1]. Emosi memengaruhi mekanisme produksi suara,

seperti laju pernapasan, ketegangan pita suara, dan artikulasi, sehingga setiap emosi meninggalkan jejak akustik yang berbeda. Emosi dengan *arousal* tinggi seperti marah dan senang cenderung memiliki *pitch* dan energi yang lebih tinggi, sedangkan sedih ditandai energi rendah dan tempo lambat [8]. Kemiripan profil akustik antaremosi, misalnya netral dan tenang atau senang dan terkejut, menjadi sumber utama kesalahan klasifikasi [3].

2.3.2. Sinyal Ucapan dan Short-Time Fourier Transform

Sinyal ucapan digital adalah deret sampel amplitudo yang diambil pada laju pencuplikan (*sampling rate*) tertentu. Karena karakteristik ucapan berubah terhadap waktu, analisis dilakukan pada potongan pendek (*frame*) berdurasi 20–40 milidetik yang dianggap stasioner, dengan pergeseran (*hop*) antarframe yang saling tumpang tindih. Setiap *frame* dikalikan dengan fungsi jendela (*window*), misalnya Hann atau Hamming, untuk mengurangi kebocoran spektral, lalu ditransformasikan ke domain frekuensi menggunakan *Short-Time Fourier Transform* (STFT) sebagaimana Persamaan (2.1).

$$X(m,k) = \sum_{n=0}^{N-1} x\,(n + mH)\, w(n)\, e^{-j2\pi kn/N} \tag{2.1}$$

dengan $x(n)$ sebagai sinyal masukan, $w(n)$ fungsi jendela, N ukuran FFT, H panjang *hop*, m indeks *frame*, dan k indeks bin frekuensi. Besaran $|X(m,k)|^2$ disebut *power spectrogram*.

2.3.3. Mel Spectrogram dan Log-Mel Spectrogram

Pendengaran manusia lebih peka terhadap perbedaan frekuensi rendah dibanding frekuensi tinggi. Skala Mel memodelkan persepsi tersebut melalui pemetaan frekuensi f (Hz) menjadi frekuensi Mel pada Persamaan (2.2) [15].

$$f_{mel} = 2595 \log_{10}\left(1 + \frac{f}{700}\right) \tag{2.2}$$

Mel spectrogram diperoleh dengan menerapkan sekumpulan filter segitiga (*Mel filterbank*) $H_b(k)$ yang tersebar merata pada skala Mel terhadap *power spectrogram*. Nilai energinya kemudian dikompresi secara logaritmik (desibel) sehingga rentang dinamikanya lebih mendekati persepsi pendengaran, menghasilkan Log-Mel Spectrogram pada Persamaan (2.3).

$$S(b,m) = 10 \log_{10}\left(\sum_{k=0}^{N/2} H_b\,(k)\,|X(m,k)|^2 + \epsilon\right) \tag{2.3}$$

dengan *b* indeks pita Mel dan ε konstanta kecil untuk menghindari logaritma nol. Log-Mel Spectrogram berbentuk matriks berukuran (jumlah pita Mel × jumlah *frame*) yang dapat diperlakukan sebagai citra kanal tunggal [6].

2.3.4. Mel-Frequency Cepstral Coefficients

MFCC diperoleh dengan menerapkan *Discrete Cosine Transform* (DCT) pada Log-Mel Spectrogram untuk mendekorelasi energi antarpita dan memadatkan informasi selubung spektral (*spectral envelope*) ke sejumlah kecil koefisien [15], sebagaimana Persamaan (2.4).

$$c_n(m) = \sum_{b=1}^{B} S\,(b,m)\cos\left[\frac{\pi n}{B}\left(b-\frac{1}{2}\right)\right] \tag{2.4}$$

dengan *B* jumlah pita Mel dan *n* indeks koefisien. MFCC banyak digunakan pada SER karena ringkas dan efektif [7], [3], [4]. Namun, DCT membuang sebagian struktur lokal antarpita frekuensi yang berdekatan, sedangkan Log-Mel Spectrogram mempertahankan struktur waktu-frekuensi tersebut sehingga secara teoretis lebih sesuai untuk operasi konvolusi dua dimensi [6], [11]. Apabila MFCC disusun per *frame* menjadi matriks (koefisien × waktu), representasi ini disebut MFCC-2D dalam penelitian ini.

2.3.5. Augmentasi Data Audio

Augmentasi data menambah variasi data latih secara sintetis untuk meningkatkan generalisasi model dan mengurangi *overfitting* pada dataset kecil [5]. Teknik pada domain gelombang (*waveform*) meliputi penambahan derau (*noise*) dengan *signal-to-noise ratio* (SNR) tertentu, *pitch shifting* untuk menggeser nada tanpa mengubah durasi, dan *time stretching* untuk mengubah tempo tanpa mengubah nada. Pada domain fitur, SpecAugment menutup (*masking*) sejumlah pita frekuensi dan rentang waktu secara acak pada *spectrogram* sehingga model tidak bergantung pada pola lokal tertentu [16]. Augmentasi hanya boleh diterapkan pada data latih setelah pembagian data agar tidak terjadi kebocoran informasi ke data validasi dan uji [5].

2.3.6. Convolutional Neural Network

CNN adalah jaringan saraf tiruan yang menggunakan operasi konvolusi untuk mengekstraksi fitur lokal secara hierarkis; lapisan awal mempelajari pola sederhana, sedangkan lapisan yang lebih dalam mempelajari pola yang lebih abstrak [9]. Pada konvolusi dua dimensi, sebuah kernel *W* berukuran *u*×*v* digeser pada peta masukan *X*

dengan *d* kanal untuk menghasilkan peta fitur *Y* pada kanal keluaran *c*, sebagaimana Persamaan (2.5).

$$Y(i,j,c) = f(\sum_u \sum_v \sum_d W_c(u,v,d)\, X(i+u,\, j+v,\, d) + b_c) \tag{2.5}$$

dengan b_c sebagai bias dan *f* fungsi aktivasi. Fungsi aktivasi yang umum digunakan adalah *Rectified Linear Unit* (ReLU) pada Persamaan (2.6).

$$f(z) = \max(0, z) \tag{2.6}$$

Komponen pendukung CNN yang digunakan dalam penelitian ini adalah sebagai berikut.

- ***Batch normalization*** menormalkan keluaran lapisan berdasarkan rerata μ_B dan varians σ^2_B pada setiap *mini-batch*, kemudian melakukan penskalaan γ dan pergeseran β yang dapat dipelajari, sebagaimana Persamaan (2.7). Teknik ini menstabilkan dan mempercepat pelatihan [17].
- ***Max pooling*** mereduksi dimensi spasial dengan mengambil nilai maksimum pada jendela tertentu (misalnya 2×2), sehingga komputasi berkurang dan model lebih toleran terhadap pergeseran kecil.
- ***Dropout*** menonaktifkan sebagian neuron secara acak selama pelatihan untuk mencegah ko-adaptasi neuron dan mengurangi *overfitting* [18].
- ***Global average pooling*** (GAP) merata-ratakan setiap peta fitur berukuran *H*×*W* menjadi satu nilai, sebagaimana Persamaan (2.8), sehingga jumlah parameter lapisan *dense* sesudahnya jauh lebih kecil dibanding operasi *flatten* [19].
- ***Softmax*** pada lapisan keluaran mengubah skor z_k menjadi probabilitas untuk *K* kelas, sebagaimana Persamaan (2.9), dan model dilatih dengan meminimalkan *categorical cross-entropy* pada Persamaan (2.10) menggunakan *optimizer* Adam [20].

$$\hat{z} = \frac{z-\mu_B}{\sqrt{\sigma_B^2+\epsilon}}, \quad y = \gamma\hat{z} + \beta \tag{2.7}$$

$$g_c = \frac{1}{H\,W}\sum_{i=1}^{H}\sum_{j=1}^{W} Y(i,j,c) \tag{2.8}$$

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}} \tag{2.9}$$

$$\mathcal{L} = -\sum_{k=1}^{K} y_k \log \hat{y}_k \tag{2.10}$$

dengan y_k label sebenarnya dalam bentuk *one-hot* dan $\hat{y}_k$ probabilitas hasil prediksi untuk kelas ke-*k*.

2.3.7. 2D-CNN pada Representasi Waktu-Frekuensi

Pada CNN satu dimensi, kernel hanya bergeser sepanjang sumbu waktu dan seluruh fitur pada satu *frame* diperlakukan sebagai kanal, atau bahkan hanya diterapkan pada vektor statistik tanpa dimensi waktu. Pada 2D-CNN, kernel bergeser pada sumbu waktu dan frekuensi sekaligus, sehingga model dapat menangkap pola lokal seperti lintasan formant, harmonik, dan perubahan energi, serta lebih toleran terhadap pergeseran frekuensi akibat perbedaan karakter suara antarpenutur [11], [6]. Keunggulan 2D-CNN dibanding CNN 1D dan LSTM pada data emosi ucapan telah dilaporkan oleh [7], dan pemanfaatan *spectrogram* sebagai masukan CNN telah banyak diteliti [10], [21].

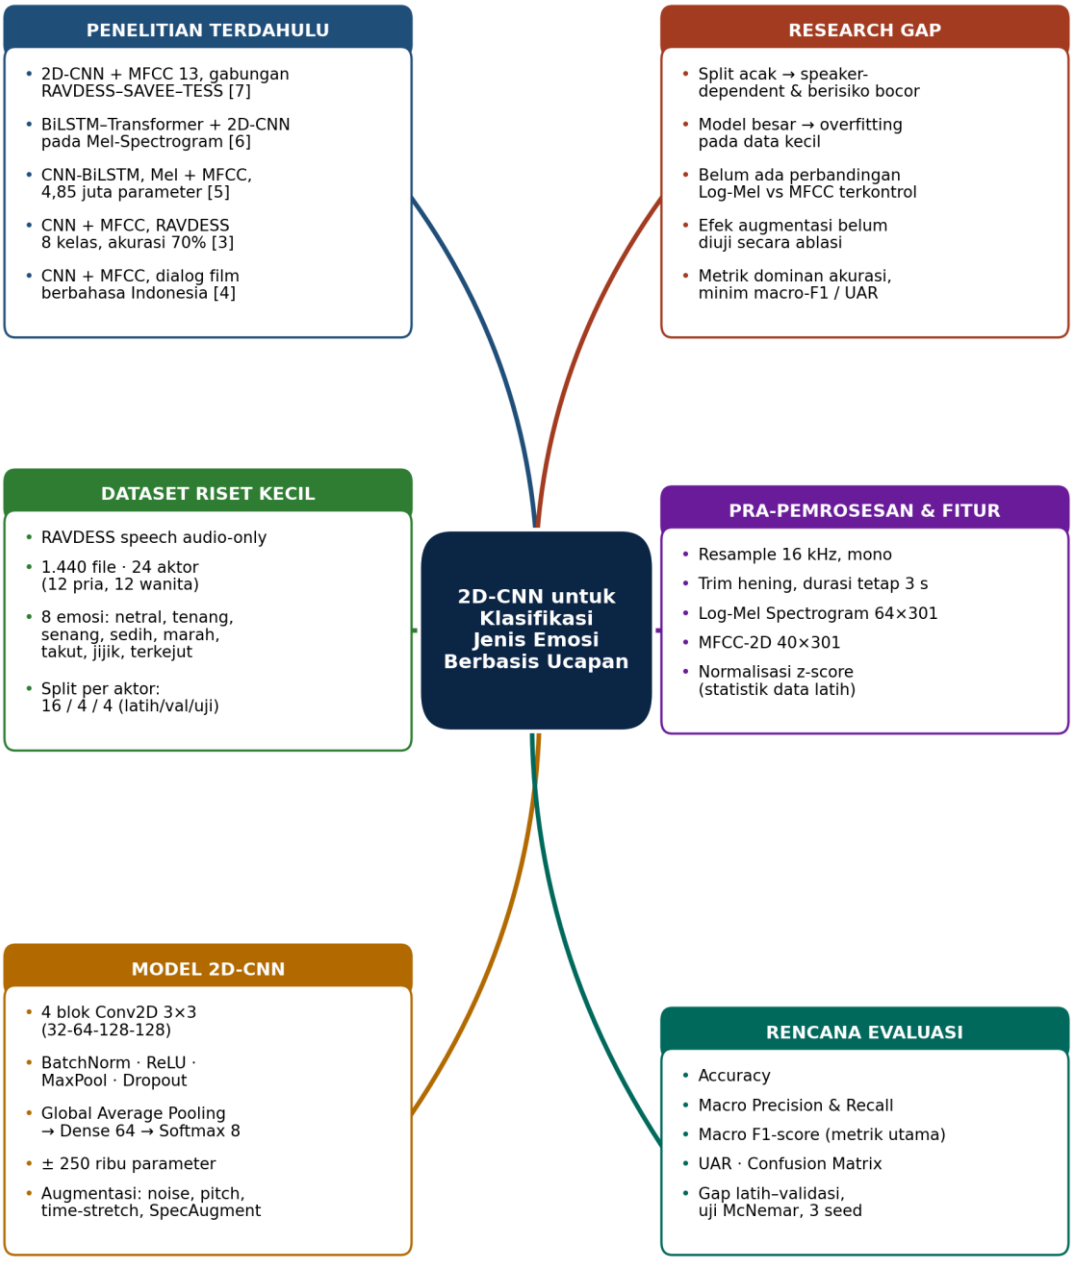
2.3.8. Overfitting dan Evaluasi Speaker-Independent

Overfitting adalah kondisi ketika model mempelajari detail dan derau data latih secara berlebihan sehingga kinerjanya pada data baru menurun; kondisi ini dipicu oleh data latih yang sedikit, model yang terlalu kompleks, atau pelatihan yang terlalu lama [22]. Indikator praktisnya adalah selisih yang besar antara akurasi data latih dan data validasi.

Pada SER, skema evaluasi dibedakan menjadi *speaker-dependent* dan *speaker-independent*. Pada skema *speaker-dependent*, ucapan dari penutur yang sama dapat berada pada data latih dan data uji, sehingga model dapat memanfaatkan karakteristik suara penutur. Skema *speaker-independent* memisahkan penutur secara tegas antara data latih dan data uji, sehingga lebih mencerminkan kondisi nyata ketika sistem digunakan oleh orang yang belum pernah dikenal [8]. Kebocoran data (*data leakage*) juga dapat terjadi apabila normalisasi atau augmentasi dihitung dari seluruh data sebelum dibagi; oleh karena itu, statistik normalisasi harus dihitung dari data latih saja.

2.4. Research Mind Map

Research mind map digunakan untuk memvisualisasikan keterkaitan antara penelitian terdahulu, celah penelitian, dan komponen penelitian yang diusulkan. Topik utama penelitian ditempatkan di pusat, kemudian dikembangkan ke enam cabang: penelitian terdahulu, *research gap*, dataset riset kecil, pra-pemrosesan dan fitur, model 2D-CNN, serta rencana evaluasi, sebagaimana ditunjukkan pada Gambar 2.1.



Gambar 2.1. Research Mind Map

Cabang penelitian terdahulu dan *research gap* menjadi dasar perumusan masalah. Cabang dataset, pra-pemrosesan dan fitur, serta model 2D-CNN merupakan respons metodologis terhadap celah tersebut, sedangkan cabang rencana evaluasi memastikan setiap rumusan masalah dapat dijawab dengan metrik yang terukur.

2.5. Hipotesis Penelitian

Berdasarkan landasan teori dan kajian penelitian terdahulu, hipotesis penelitian dirumuskan sebagai berikut.

1. **H1:** 2D-CNN dengan masukan Log-Mel Spectrogram menghasilkan *macro F1-score* yang lebih tinggi dibanding masukan MFCC-2D, karena Log-Mel

mempertahankan struktur lokal waktu-frekuensi yang dapat dimanfaatkan konvolusi dua dimensi.

2. **H2:** Augmentasi data pada data latih memperkecil selisih akurasi latih dan validasi serta meningkatkan *macro F1-score* pada data uji *speaker-independent*.
3. **H3:** 2D-CNN pada representasi waktu-frekuensi menghasilkan kinerja yang lebih baik dibanding *baseline* SVM pada vektor statistik MFCC.

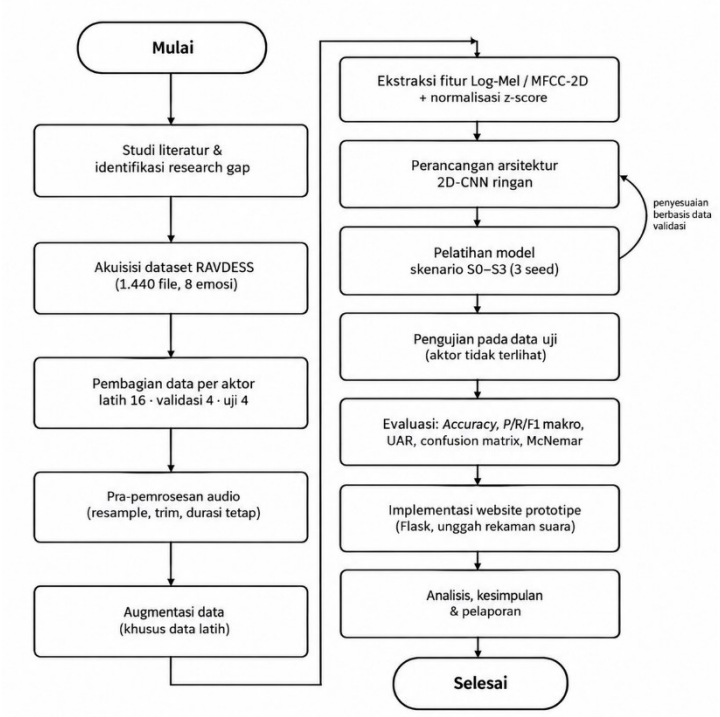
BAB III
METODOLOGI PENELITIAN

3.1. Jenis dan Pendekatan Penelitian

Penelitian ini merupakan penelitian kuantitatif dengan pendekatan eksperimen komputasional. Variabel bebas penelitian adalah jenis representasi masukan (Log-Mel Spectrogram atau MFCC-2D) dan penggunaan augmentasi data (dengan atau tanpa augmentasi). Variabel terikat adalah kinerja klasifikasi yang diukur dengan *accuracy*, *macro precision*, *macro recall* (UAR), dan *macro F1-score*. Variabel kontrol meliputi arsitektur 2D-CNN, *hyperparameter* pelatihan, pembagian data per aktor, serta nilai *random seed*, sehingga perbedaan hasil antarskenario dapat diatribusikan pada variabel bebas.

3.2. Tahapan Penelitian

Tahapan penelitian dirancang secara berurutan dari persiapan hingga pelaporan sebagaimana ditunjukkan pada Gambar 3.1. Pembagian data per aktor dilakukan sebelum pra-pemrosesan lanjutan dan augmentasi untuk mencegah kebocoran informasi antara data latih, validasi, dan uji.



Gambar 3.1. Diagram Alur Tahapan Penelitian

Penjelasan singkat setiap tahapan adalah sebagai berikut.

1. **Studi literatur dan identifikasi *research gap*:** mengkaji penelitian SER berbasis CNN dan merumuskan celah penelitian (Subbab 2.1 dan 2.2).
2. **Akuisisi dataset:** mengunduh RAVDESS bagian *speech audio-only* dan mengekstrak label emosi serta nomor aktor dari nama berkas.
3. **Pembagian data per aktor:** membentuk data latih, validasi, dan uji berdasarkan aktor.
4. **Pra-pemrosesan audio:** *resampling*, konversi *mono*, penghapusan hening, penyeragaman durasi, dan normalisasi amplitudo.
5. **Augmentasi data:** membangkitkan variasi data latih pada domain gelombang dan domain fitur.
6. **Ekstraksi fitur:** menghitung Log-Mel Spectrogram dan MFCC-2D, lalu melakukan normalisasi *z-score* berbasis statistik data latih.
7. **Perancangan arsitektur dan pelatihan:** membangun 2D-CNN ringan dan melatihnya pada skenario S0–S3; penyesuaian konfigurasi hanya didasarkan pada data validasi.
8. **Pengujian dan evaluasi:** menguji model akhir satu kali pada data uji, menghitung metrik evaluasi, dan menganalisis *confusion matrix*.
9. **Implementasi *website*:** mengintegrasikan model terbaik ke dalam prototipe *website* berbasis Flask dan mengujinya secara fungsional.
10. **Analisis dan pelaporan:** menjawab rumusan masalah, menguji hipotesis, dan menyusun kesimpulan.

3.3. Dataset Rencana Riset Kecil

3.3.1. Sumber dan Spesifikasi Dataset

Dataset yang digunakan adalah *The Ryerson Audio-Visual Database of Emotional Speech and Song* (RAVDESS) [12]. Dataset ini dipilih karena bersifat publik, memiliki label yang telah divalidasi oleh penilai manusia, berukuran kecil sehingga sesuai untuk riset skala mahasiswa, menyediakan identitas aktor yang memungkinkan evaluasi *speaker-independent*, dan telah digunakan pada penelitian acuan [7], [6], [3] sehingga hasilnya dapat dibandingkan. Spesifikasi dataset ditunjukkan pada Tabel 3.1.

Tabel 3.1. Spesifikasi Dataset RAVDESS yang Digunakan

Atribut	Keterangan
Nama dataset	RAVDESS, bagian *Audio-only Speech* (Audio_Speech_Actors_01-24)
Sumber	Zenodo (doi: 10.5281/zenodo.1188976) dan cerminan Kaggle (kaggle.com/uwrfkaggler/ravdess-emotional-speech-audio)
Lisensi	Creative Commons BY-NC-SA 4.0 (penggunaan nonkomersial, termasuk penelitian akademik)
Jumlah berkas	1.440 berkas audio
Jumlah penutur	24 aktor profesional (12 pria, 12 wanita)
Bahasa dan aksen	Bahasa Inggris, aksen netral Amerika Utara
Kalimat	Dua kalimat dengan leksikal sama: "Kids are talking by the door" dan "Dogs are sitting by the door"
Kelas emosi	8 kelas: netral, tenang, senang, sedih, marah, takut, jijik, terkejut
Intensitas	Normal dan kuat (kelas netral hanya intensitas normal)
Format audio	WAV, 16-bit, 48 kHz
Durasi per berkas	Sekitar 3–4 detik (termasuk jeda hening); total sekitar 1,5 jam audio
Ukuran berkas	Sekitar 200 MB (arsip ZIP)
Jenis ucapan	Diperankan (*acted*), direkam di studio

3.3.2. Struktur Penamaan Berkas dan Pelabelan

Label pada RAVDESS tidak disimpan dalam berkas terpisah, melainkan dikodekan pada nama berkas yang terdiri atas tujuh kode numerik dua digit [12]. Contohnya, berkas 03-01-06-01-02-01-12.wav berarti *audio-only*, *speech*, emosi takut, intensitas normal, kalimat "Dogs are sitting by the door", pengulangan pertama, dan aktor ke-12 (wanita). Arti setiap kode ditunjukkan pada Tabel 3.2. Pelabelan dilakukan secara otomatis dengan memecah nama berkas menggunakan skrip Python.

Tabel 3.2. Struktur Kode Nama Berkas RAVDESS

Posisi	Atribut	Kode dan Arti
1	Modalitas	01 = *full-AV*, 02 = *video-only*, 03 = *audio-only*
2	Kanal vokal	01 = *speech*, 02 = *song*
3	Emosi	01 = netral, 02 = tenang, 03 = senang, 04 = sedih, 05 = marah, 06 = takut, 07 = jijik, 08 = terkejut
4	Intensitas	01 = normal, 02 = kuat
5	Kalimat	01 = "Kids are talking by the door", 02 = "Dogs are sitting by the door"
6	Pengulangan	01 = pengulangan pertama, 02 = pengulangan kedua
7	Aktor	01–24; nomor ganjil = pria, nomor genap = wanita

3.3.3. Distribusi Kelas Emosi

Setiap aktor merekam 60 ucapan, yaitu 4 ucapan untuk kelas netral (2 kalimat × 2 pengulangan × 1 intensitas) dan 8 ucapan untuk setiap kelas lainnya (2 kalimat × 2 pengulangan × 2 intensitas). Distribusi kelas ditunjukkan pada Tabel 3.3. Kelas

netral berjumlah setengah dari kelas lain, sehingga penelitian menggunakan metrik makro dan bobot kelas (*class weight*) untuk mengompensasi ketidakseimbangan tersebut.

Tabel 3.3. Distribusi Kelas Emosi pada RAVDESS Speech

Kode	Emosi (Inggris)	Emosi (Indonesia)	Per Aktor	Total Berkas	Proporsi
01	*Neutral*	Netral	4	96	6,67%
02	*Calm*	Tenang	8	192	13,33%
03	*Happy*	Senang	8	192	13,33%
04	*Sad*	Sedih	8	192	13,33%
05	*Angry*	Marah	8	192	13,33%
06	*Fearful*	Takut	8	192	13,33%
07	*Disgust*	Jijik	8	192	13,33%
08	*Surprised*	Terkejut	8	192	13,33%
	Total		**60**	**1.440**	**100%**

3.3.4. Pembagian Data Speaker-Independent

Data dibagi berdasarkan aktor agar tidak ada penutur yang muncul pada lebih dari satu subset. Aktor 01–16 digunakan sebagai data latih, aktor 17–20 sebagai data validasi, dan aktor 21–24 sebagai data uji. Karena nomor ganjil menyatakan pria dan nomor genap menyatakan wanita, setiap subset memiliki jumlah pria dan wanita yang seimbang, sebagaimana ditunjukkan pada Tabel 3.4. Data validasi digunakan untuk *early stopping* dan pemilihan konfigurasi, sedangkan data uji hanya digunakan satu kali pada evaluasi akhir.

Tabel 3.4. Rencana Pembagian Data Berdasarkan Aktor

Subset	Aktor	Pria / Wanita	Jumlah Berkas	Netral	Kelas Lain (masing-masing)	Proporsi
Latih	01–16	8 / 8	960	64	128	66,7%
Validasi	17–20	2 / 2	240	16	32	16,7%
Uji	21–24	2 / 2	240	16	32	16,7%
Total	**24 aktor**	**12 / 12**	**1.440**	**96**	**192**	**100%**

Apabila waktu dan kuota komputasi memungkinkan, konfigurasi terbaik juga akan divalidasi dengan *cross-validation* berbasis kelompok aktor (6 *fold*, masing-masing 4 aktor sebagai data uji) untuk memastikan hasil tidak bergantung pada satu pembagian aktor tertentu.

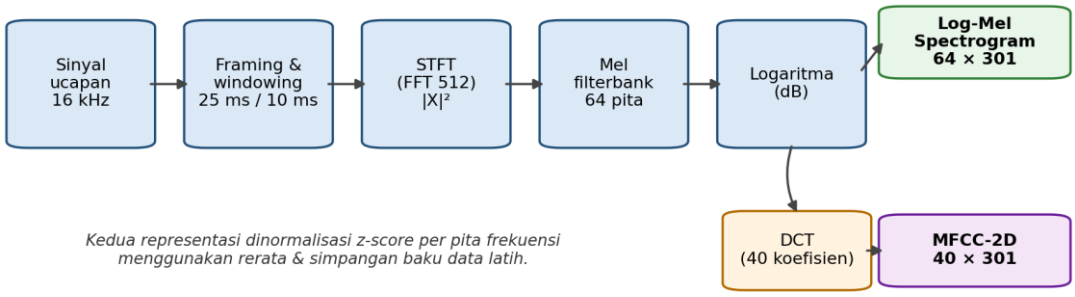
3.4. Pra-pemrosesan Audio

Pra-pemrosesan dilakukan menggunakan pustaka librosa [23] dengan langkah-langkah sebagai berikut.

1. ***Resampling* dan konversi *mono*:** audio 48 kHz diturunkan menjadi 16 kHz satu kanal. Sebagian besar energi ucapan berada di bawah 8 kHz, sehingga langkah ini mengurangi beban komputasi sekitar tiga kali lipat tanpa menghilangkan informasi penting.
2. **Penghapusan hening (*silence trimming*):** bagian hening di awal dan akhir rekaman dihapus menggunakan fungsi *trim* dengan ambang 30 dB di bawah puncak, mengikuti pendekatan [6].
3. **Penyeragaman durasi:** setiap sinyal diseragamkan menjadi L sampel. Nilai awal ditetapkan 3 detik (48.000 sampel) dan akan dikonfirmasi dari persentil ke-95 durasi data latih setelah *trimming*. Sinyal yang lebih panjang dipotong di bagian tengah, sedangkan sinyal yang lebih pendek diberi *zero padding* secara simetris.
4. **Normalisasi amplitudo:** setiap sinyal dibagi dengan nilai absolut maksimumnya sehingga berada pada rentang [−1, 1] dan perbedaan volume perekaman tidak memengaruhi model.

3.5. Ekstraksi Fitur

Dua representasi waktu-frekuensi diekstraksi dari sinyal hasil pra-pemrosesan, yaitu Log-Mel Spectrogram dan MFCC-2D, dengan alur sebagaimana Gambar 3.2. Kedua representasi menggunakan parameter *framing* yang sama agar perbandingan bersifat adil; parameter lengkap ditunjukkan pada Tabel 3.5.



Gambar 3.2. Alur Ekstraksi Fitur Log-Mel Spectrogram dan MFCC-2D

Tabel 3.5. Parameter Ekstraksi Fitur

Parameter	Nilai	Keterangan
Sampling rate	16.000 Hz	Hasil *resampling*

Parameter	Nilai	Keterangan
Panjang jendela (*win_length*)	400 sampel	25 ms
Panjang *hop*	160 sampel	10 ms
Ukuran FFT (*n_fft*)	512	Resolusi frekuensi 31,25 Hz
Fungsi jendela	Hann	—
Jumlah pita Mel	64	Rentang 20–8.000 Hz
Kompresi	Logaritmik (dB)	Persamaan (2.3)
Jumlah koefisien MFCC	40	DCT tipe II dari 64 pita Mel
Jumlah *frame* (*T*)	301	Durasi 3 detik, Persamaan (3.1)
Bentuk masukan Log-Mel	64 × 301 × 1	Pita Mel × *frame* × kanal
Bentuk masukan MFCC-2D	40 × 301 × 1	Koefisien × *frame* × kanal

Jumlah *frame* untuk sinyal sepanjang L sampel dengan *hop* H dan *padding* di tengah (*center*) dihitung menggunakan Persamaan (3.1).

$$T = 1 + \left\lfloor \frac{L}{H} \right\rfloor = 1 + \frac{48000}{160} = 301 \tag{3.1}$$

Setiap representasi kemudian dinormalisasi dengan *z-score* per pita frekuensi (atau per koefisien) menggunakan rerata μ_b dan simpangan baku σ_b yang dihitung hanya dari data latih, sebagaimana Persamaan (3.2). Statistik yang sama diterapkan pada data validasi dan data uji untuk mencegah kebocoran data.

$$\tilde{x}_{b,t} = \frac{x_{b,t} - \mu_b}{\sigma_b} \tag{3.2}$$

3.6. Augmentasi Data

Augmentasi hanya diterapkan pada data latih. Setiap berkas latih dibangkitkan menjadi dua salinan tambahan dengan teknik augmentasi domain gelombang yang dipilih secara acak, sehingga data latih bertambah dari 960 menjadi 2.880 sampel. Selain itu, SpecAugment diterapkan secara *on-the-fly* pada setiap *epoch* [16]. Rincian teknik augmentasi ditunjukkan pada Tabel 3.6.

Tabel 3.6. Rencana Teknik Augmentasi Data

Teknik	Parameter	Domain	Tujuan
Gaussian noise	SNR acak 15–30 dB, Persamaan (3.3)	Gelombang	Ketahanan terhadap derau perekaman
Pitch shifting	±2 *semitone*	Gelombang	Variasi nada antarpenutur
Time stretching	Faktor 0,9–1,1, lalu durasi diseragamkan ulang	Gelombang	Variasi tempo bicara
SpecAugment	2 *frequency mask* (≤ 8 pita) dan 2 *time mask* (≤ 30 *frame*)	Fitur	Mencegah ketergantungan pada pola lokal tertentu

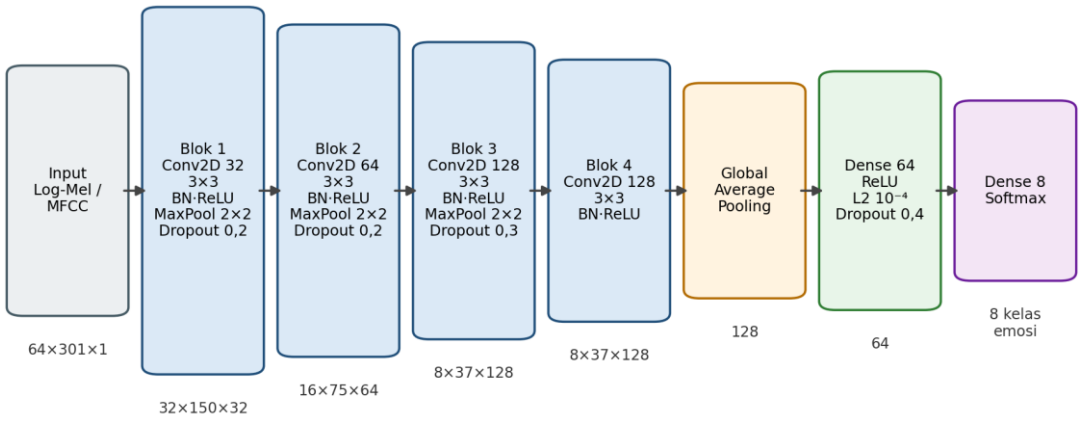
Penambahan derau dengan SNR yang ditentukan dilakukan menggunakan Persamaan (3.3).

$$x_{aug}(n) = x(n) + \sqrt{\frac{P_x}{10^{SNR/10}}}\ \eta(n), \quad \eta(n) \sim \mathcal{N}(0,1) \tag{3.3}$$

dengan P_x daya rata-rata sinyal asli dan $\eta(n)$ derau Gaussian berdistribusi normal standar.

3.7. Rancangan Arsitektur 2D-CNN

Arsitektur 2D-CNN dirancang ringan agar proporsional dengan ukuran data latih dan sumber daya komputasi yang tersedia. Model terdiri atas empat blok konvolusi dengan kernel 3×3, *padding same*, dan jumlah filter 32, 64, 128, dan 128. Setiap blok terdiri atas Conv2D, *batch normalization*, dan ReLU; tiga blok pertama diikuti *max pooling* 2×2 dan *dropout*. Keluaran blok keempat diringkas dengan *global average pooling*, kemudian diteruskan ke lapisan *dense* 64 neuron, *dropout* 0,4, dan lapisan keluaran *softmax* 8 kelas. Regularisasi L2 sebesar 10^{-4} diterapkan pada seluruh kernel konvolusi dan *dense*. Ilustrasi arsitektur ditunjukkan pada Gambar 3.3 dan rinciannya pada Tabel 3.7.



Gambar 3.3. Rancangan Arsitektur 2D-CNN Ringan

Tabel 3.7. Rincian Lapisan Arsitektur 2D-CNN (Masukan Log-Mel 64×301×1)

Lapisan	Konfigurasi	Bentuk Keluaran	Parameter
Input	—	64 × 301 × 1	0
Conv2D-1 + BN + ReLU	32 filter 3×3, *same*	64 × 301 × 32	320 + 128
MaxPool + Dropout	2×2; 0,2	32 × 150 × 32	0
Conv2D-2 + BN + ReLU	64 filter 3×3, *same*	32 × 150 × 64	18.496 + 256
MaxPool + Dropout	2×2; 0,2	16 × 75 × 64	0
Conv2D-3 + BN + ReLU	128 filter 3×3, *same*	16 × 75 × 128	73.856 + 512
MaxPool + Dropout	2×2; 0,3	8 × 37 × 128	0
Conv2D-4 + BN + ReLU	128 filter 3×3, *same*	8 × 37 × 128	147.584 + 512

Lapisan	Konfigurasi	Bentuk Keluaran	Parameter
Global Average Pooling	—	128	0
Dense + ReLU	64 neuron, L2 10^{-4}	64	8.256
Dropout	0,4	64	0
Dense (Softmax)	8 neuron	8	520
Total			**250.440**

Dari 250.440 parameter, sebanyak 249.736 parameter dapat dilatih dan 704 parameter merupakan statistik bergerak *batch normalization*. Jumlah ini sekitar 19 kali lebih kecil dibanding model CNN-BiLSTM pada [5]. Karena *global average pooling* menghasilkan vektor berukuran tetap, jumlah parameter model untuk masukan MFCC-2D (40×301×1) sama persis, sehingga perbandingan representasi tidak dipengaruhi kapasitas model.

3.8. Skenario Eksperimen dan Konfigurasi Pelatihan

Eksperimen terdiri atas satu *baseline* dan tiga skenario 2D-CNN sebagaimana Tabel 3.8. Skenario S1 dan S2 menjawab rumusan masalah kedua, skenario S3 menjawab rumusan masalah ketiga, dan perbandingan seluruh skenario terhadap S0 menguji hipotesis H3. Setiap skenario 2D-CNN dijalankan dengan tiga *random seed* (42, 123, dan 2026), dan hasilnya dilaporkan sebagai rerata ± simpangan baku.

Tabel 3.8. Skenario Eksperimen

Kode	Model dan Masukan	Augmentasi	Jumlah Run	Tujuan
S0	SVM (kernel RBF) pada vektor statistik MFCC (rerata dan simpangan baku 40 koefisien = 80 dimensi)	Tidak	1	*Baseline* pembanding (H3)
S1	2D-CNN + MFCC-2D (40×301)	Tidak	3	Kinerja representasi MFCC-2D
S2	2D-CNN + Log-Mel (64×301)	Tidak	3	Kinerja representasi Log-Mel (H1)
S3	2D-CNN + representasi terbaik dari S1/S2	Ya (Tabel 3.6)	3	Pengaruh augmentasi (H2)

Parameter C dan γ pada *baseline* SVM dipilih dengan *grid search* sederhana pada data validasi menggunakan scikit-learn [24]. Konfigurasi pelatihan 2D-CNN ditunjukkan pada Tabel 3.9 dan diberlakukan sama untuk seluruh skenario.

Tabel 3.9. Konfigurasi Pelatihan 2D-CNN

Parameter	Nilai
Optimizer	Adam (*learning rate* awal 0,001; $\beta_1 = 0{,}9$; $\beta_2 = 0{,}999$) [20]
Fungsi *loss*	*Categorical cross-entropy*
Batch size	32

Parameter	Nilai
Maksimum *epoch*	100
Early stopping	Memantau *val_loss*, *patience* 15, mengembalikan bobot terbaik
ReduceLROnPlateau	Faktor 0,5; *patience* 5; *learning rate* minimum 10^{-5}
Bobot kelas	*Balanced* (kelas netral diberi bobot lebih besar)
Random seed	42, 123, dan 2026
Pemilihan model	Berdasarkan *macro F1-score* data validasi; data uji tidak digunakan untuk penyesuaian

Dengan ukuran model sekitar 250 ribu parameter dan 2.880 sampel latih, satu kali pelatihan diperkirakan memerlukan beberapa menit hingga sekitar 15 menit pada GPU NVIDIA T4 Google Colab. Dengan total sepuluh *run*, seluruh eksperimen dapat diselesaikan dalam beberapa sesi Colab gratis.

3.9. Rencana Evaluation Metric

Evaluasi dilakukan pada data uji (aktor 21–24, 240 berkas asli tanpa augmentasi). Dasar perhitungan seluruh metrik adalah *confusion matrix* berukuran $K \times K$ dengan $K = 8$, yaitu tabel yang membandingkan label sebenarnya (baris) dengan label prediksi (kolom). Untuk setiap kelas k dengan pendekatan *one-vs-rest*, *true positive* (TP_k) adalah sampel kelas k yang diprediksi benar, *false positive* (FP_k) adalah sampel kelas lain yang diprediksi sebagai k, dan *false negative* (FN_k) adalah sampel kelas k yang diprediksi sebagai kelas lain [13].

3.9.1. Accuracy

Accuracy mengukur proporsi prediksi benar terhadap seluruh N sampel uji, sebagaimana Persamaan (3.4). Metrik ini setara dengan *weighted accuracy* dan mudah dibandingkan dengan penelitian terdahulu, tetapi dapat bias terhadap kelas yang lebih banyak.

$$Accuracy = \frac{\sum_{k=1}^{K} TP_k}{N} \tag{3.4}$$

3.9.2. Precision, Recall, dan F1-Score

Precision mengukur ketepatan prediksi suatu kelas, *recall* mengukur kemampuan model menemukan seluruh sampel suatu kelas, dan *F1-score* merupakan rerata harmonik keduanya, sebagaimana Persamaan (3.5) hingga (3.7).

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \tag{3.5}$$

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \tag{3.6}$$

$$F1_k = \frac{2 \times Precision_k \times Recall_k}{Precision_k + Recall_k} \quad (3.7)$$

3.9.3. Macro F1-Score dan Unweighted Average Recall

Agar setiap kelas emosi berbobot sama tanpa dipengaruhi jumlah sampel, digunakan rerata makro. *Macro F1-score* pada Persamaan (3.8) ditetapkan sebagai metrik utama penelitian, sedangkan *Unweighted Average Recall* (UAR) pada Persamaan (3.9), yang setara dengan *macro recall*, digunakan karena merupakan metrik standar pada penelitian SER dan memungkinkan perbandingan dengan *unweighted accuracy* pada [6] [8].

$$Macro\text{-}F1 = \frac{1}{K} \sum_{k=1}^{K} F\ 1_k \quad (3.8)$$

$$UAR = \frac{1}{K} \sum_{k=1}^{K} R\ ecall_k \quad (3.9)$$

3.9.4. Confusion Matrix dan Analisis Overfitting

Confusion matrix ternormalisasi per baris digunakan untuk mengidentifikasi pasangan emosi yang sering tertukar, misalnya netral–tenang dan senang–terkejut. Tingkat *overfitting* dipantau melalui kurva *accuracy* dan *loss* per *epoch* serta selisih akurasi latih dan validasi pada *epoch* terbaik, sebagaimana Persamaan (3.10).

$$\Delta_{gap} = Accuracy_{latih} - Accuracy_{validasi} \quad (3.10)$$

3.9.5. Uji Signifikansi McNemar

Untuk menentukan apakah perbedaan dua skenario (S1 dan S2, serta skenario terbaik tanpa augmentasi dan S3) bermakna secara statistik, digunakan uji McNemar pada prediksi data uji yang sama [25], sebagaimana Persamaan (3.11). Nilai n_{01} adalah jumlah sampel yang diprediksi benar oleh model pertama tetapi salah oleh model kedua, dan n_{10} sebaliknya. Perbedaan dinyatakan signifikan apabila nilai $p < 0{,}05$.

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}} \quad (3.11)$$

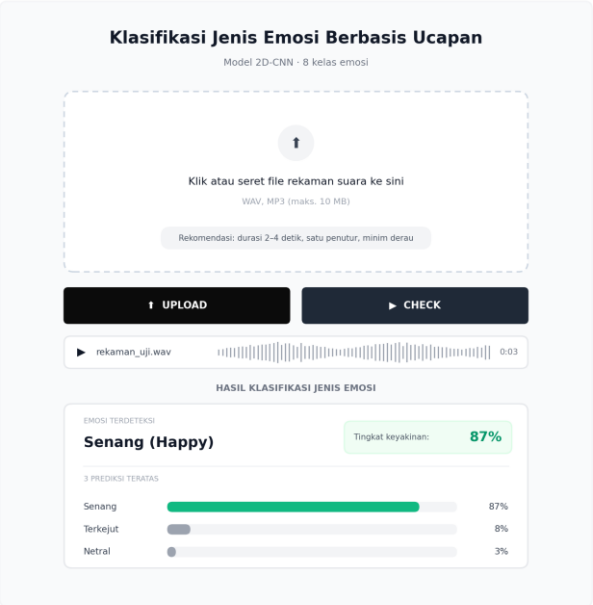
Ringkasan rencana *evaluation metric* ditunjukkan pada Tabel 3.10. Target indikatif ditetapkan lebih rendah dari angka pada penelitian acuan karena skema *speaker-independent* lebih ketat dibanding pembagian data secara acak; target tersebut berfungsi sebagai acuan analisis, bukan klaim hasil.

Tabel 3.10. Ringkasan Rencana Evaluation Metric

Metrik	Fungsi	Alasan Pemilihan	Target Indikatif
Macro F1-score (utama)	Keseimbangan *precision* dan *recall* rata-rata seluruh kelas	Tidak bias terhadap jumlah sampel; kelas netral hanya setengah kelas lain	≥ 0,55
Accuracy	Proporsi prediksi benar keseluruhan	Komparabilitas dengan penelitian terdahulu	≥ 60%
UAR (*macro recall*)	Rerata kemampuan mengenali tiap kelas	Metrik standar SER, setara *unweighted accuracy*	≥ 0,55
Macro precision	Rerata ketepatan prediksi tiap kelas	Mengukur tingkat *false positive* per kelas	≥ 0,55
Precision, *recall*, F1 per kelas	Kinerja tiap emosi	Mengidentifikasi emosi yang sulit dikenali	—
Confusion matrix	Pola kesalahan antarkelas	Menjawab rumusan masalah keempat	—
Gap latih–validasi	Indikator *overfitting*	Menguji hipotesis H2	< 15 poin
Uji McNemar	Signifikansi perbedaan dua model	Memastikan perbedaan bukan kebetulan	$p < 0,05$

3.10. Implementasi *Website*

Setelah model terbaik diperoleh dari skenario eksperimen, tahap selanjutnya adalah implementasi *website*. Implementasi *website* menggunakan *framework* Flask dan dimulai dengan menyusun rancangan alur serta model tampilan untuk memudahkan proses pengembangan. *Website* ini berfungsi sebagai antarmuka yang memungkinkan pengguna mengunggah rekaman suara, lalu jenis emosinya diklasifikasikan oleh model 2D-CNN yang telah dilatih. Rancangan model tampilan *website* ditampilkan pada Gambar 3.4.



Gambar 3.4. *Wireframe Website*

DAFTAR PUSTAKA

[1] M. B. Akçay and K. Oğuz, “Speech emotion recognition: Emotional models, databases, features, preprocessing methods, supporting modalities, and classifiers,” *Speech Communication*, vol. 116, pp. 56–76, 2020, doi: 10.1016/j.specom.2019.12.001.

[2] R. W. Picard, *Affective Computing*. Cambridge, MA, USA: MIT Press, 1997.

[3] F. J. Tanudjaja, E. Y. Puspaningrum, and Y. V. Via, “Klasifikasi jenis emosi melalui ucapan menggunakan metode convolutional neural network,” *Teknologi: Jurnal Ilmiah Sistem Informasi*, vol. 13, no. 2, pp. 1–11, 2023, doi: 10.26594/teknologi.v13i2.3740.

[4] T. B. Santoso, Y. K. Aini, and T. Dutono, “Speech emotion recognition of Indonesian movies by using convolutional neural network,” *JOIV: International Journal on Informatics Visualization*, vol. 9, no. 6, pp. 2569–2575, 2025.

[5] G. Maulana, W. Herdiansyah, T. Al Fayadh, M. Rizky, and Supriadin, “Klasifikasi emosi suara multi bahasa berbasis deep learning menggunakan Mel Spectrogram dan MFCC pada Indian Speech Emotion,” *Journal of Information Technology and System Integration (JITSI)*, vol. 1, no. 1, 2026.

[6] S. Kim and S.-P. Lee, “A BiLSTM–Transformer and 2D CNN architecture for emotion recognition from speech,” *Electronics*, vol. 12, no. 19, p. 4034, 2023, doi: 10.3390/electronics12194034.

[7] F. Reggiswarashari and S. W. Sihwi, “Speech emotion recognition using 2D-convolutional neural network,” *International Journal of Electrical and Computer Engineering (IJECE)*, vol. 12, no. 6, pp. 6594–6601, 2022, doi: 10.11591/ijece.v12i6.pp6594-6601.

[8] B. W. Schuller, “Speech emotion recognition: Two decades in a nutshell, benchmarks, and ongoing trends,” *Communications of the ACM*, vol. 61, no. 5, pp. 90–99, 2018, doi: 10.1145/3129340.

[9] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.

[10] W. Lim, D. Jang, and T. Lee, “Speech emotion recognition using convolutional and recurrent neural networks,” in *Proc. Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA)*, Jeju, Korea, 2016, pp. 1–4, doi: 10.1109/APSIPA.2016.7820699.

[11] J. Zhao, X. Mao, and L. Chen, “Speech emotion recognition using deep 1D & 2D CNN LSTM networks,” *Biomedical Signal Processing and Control*, vol. 47, pp. 312–323, 2019, doi: 10.1016/j.bspc.2018.08.035.

[12] S. R. Livingstone and F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English,” *PLoS ONE*, vol. 13, no. 5, p. e0196391, 2018, doi: 10.1371/journal.pone.0196391.

[13] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009, doi: 10.1016/j.ipm.2009.03.002.

[14] F. Burkhardt, A. Paeschke, M. Rolfes, W. F. Sendlmeier, and B. Weiss, “A database of German emotional speech,” in *Proc. Interspeech 2005*, Lisbon, Portugal, 2005, pp. 1517–1520.

[15] S. Davis and P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, 1980, doi: 10.1109/TASSP.1980.1163420.

[16] D. S. Park, W. Chan, Y. Zhang, C.-C. Chiu, B. Zoph, E. D. Cubuk, and Q. V. Le, “SpecAugment: A simple data augmentation method for automatic speech recognition,” in *Proc. Interspeech 2019*, Graz, Austria, 2019, pp. 2613–2617, doi: 10.21437/Interspeech.2019-2680.

[17] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *Proc. 32nd International Conference on Machine Learning (ICML)*, Lille, France, 2015, pp. 448–456.

[18] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.

[19] M. Lin, Q. Chen, and S. Yan, “Network in network,” *arXiv preprint* arXiv:1312.4400, 2013.

[20] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proc. 3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, USA, 2015, arXiv:1412.6980.

[21] D. Issa, M. F. Demirci, and A. Yazici, “Speech emotion recognition with deep convolutional neural networks,” *Biomedical Signal Processing and Control*, vol. 59, p. 101894, 2020, doi: 10.1016/j.bspc.2020.101894.

[22] X. Ying, “An overview of overfitting and its solutions,” *Journal of Physics: Conference Series*, vol. 1168, p. 022022, 2019, doi: 10.1088/1742-6596/1168/2/022022.

[23] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in Python,” in *Proc. 14th Python in Science Conference (SciPy)*, Austin, TX, USA, 2015, pp. 18–25, doi: 10.25080/Majora-7b98e3ed-003.

[24] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[25] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947, doi: 10.1007/BF02295996.